

Expressões Regulares, AWK, SED e Wildcards.



Expressões Regulares

Expressão Regular (ou **regex**, abreviação do inglês **regular expression**) provê uma forma concisa e flexível de identificar cadeias de caracteres de interesse, como caracteres particulares, palavras ou padrões de caracteres. Expressões regulares são escritas numa linguagem formal que pode ser interpretada por um processador de expressão regular, um programa que serve um gerador de analisador sintático que examina o texto e identifica as partes que casam com a especificação dada.

Vamos utilizar como ambiente de testes o arquivo **/etc/passwd** , por questões de segurança, **NÃO USE O ROOT!** Se você não sabe se você o **root** ou não, rode o comando abaixo, se for **root** o resultado vai ser **0** , para qualquer resultado diferente de zero, então **você não é root**. Rode no terminal: **id -u**

Agora dê um **cat** no arquivo **/etc/passwd**: **cat /etc/passwd** . A estrutura do arquivo é

login : **senha** : **UID** : **GID** : **Nome Completo** : **Diretório \$HOME** : **shell**

Todas as senhas estão com **X**

porque estão com engenharia reversa guardadas em outro lugar.

GREP

Em **Shell Script** geralmente usamos o comando **grep** para usar **expressões regulares**. O **grep** pode ser usado por vários nomes, e cada um deles tem sua particularidade ou nível de evolução: **grep**, **egrep**, **fgrep** e **rgrep**. Sua sintaxe é definida por: **grep [OPÇÃO] PADRÃO [ARQUIVO(s)]**. Se tratando de expressões regulares, quase tudo na verdade, a melhor forma de aprender é praticando, então, *vamos lá !*

- * pegar as linhas que contém determinado PALAVRA (root nesse caso): **grep root /etc/passwd**
- * pegar SOMENTE as linhas que COMEÇAM com determinado PALAVRA (usa-se o ^ antes da PALAVRA): **grep '^root' /etc/passwd**
- * pegar SOMENTE as linhas que TERMINAL com determinado palavra (usa-se o \$ DEPOIS da PALAVRA=bash): **grep 'bash\$' /etc/passwd**
- * pegar SOMENTE as linhas que CONTÉM PALAVRA que tem duas letras o juntas (ex.: oo) : **grep 'oo' /etc/passwd**
- * pegar SOMENTE as linhas que COMEÇAM com as letras a,e,i,o ou u ([]): **grep '^[aeiou]' /etc/passwd**
- * pegar SOMENTE as linhas que NÃO COMEÇAM com vogais (^[^): **grep '^[^aeiou]' /etc/passwd**
- * pegar SOMENTE as linhas que A SEGUNDA LETRA é uma das letras a,e,i,o ou u(.): **grep '^.[aeiou]' /etc/passwd**
- * pegar SOMENTE as linhas que COMEÇAM com uma VOGAL e TERMINAM com a PALAVRA bash: **grep '^[aeiou].*bash\$' /etc/passwd**
- * pegar SOMENTE as linhas que TENHAM EXATOS 32 caracteres (. e { }): **egrep '^.{31}\$' /etc/passwd**

Em alguns comandos usamos **egrep** e não o **grep**, porque as chaves fazem parte de um conjunto avançado de Expressões Regulares ("extended"), então o **egrep** lida melhor com elas. Se fosse para usar o **grep** normal, teria que "escapar" as chaves.

Para lista completa de possibilidade use o manual: **man grep**

AWK

AWK tem a mesma pronúncia de *Auk*, uma espécie de pássaro, mas é uma linguagem de programação interpretada que é, geralmente, usada para deixar os scripts de shell com mais recursos. Existem vários tipos de **AWK**, que nada mais são variantes de outros autores que a modificaram: **BWK**, **GAWK**, **MAWK**, **LIBAWK**, **AWKA**, **TAWK**, **JAWK**, **XGAWK**, **QSEAWK** e **BusyBox**. Também é possível usar **Expressões Regulares** com **AWK**.

Comando básico: **echo** | **awk** '{print "Hello, World"}'

Veja que usamos o comando **echo** junto com **awk**, para usar o **awk** devemos nos referir a um arquivo ou usá-la com os comandos setados no arquivo **.awk**, sendo que o cabeçalho será: **/usr/bin/awk** . Então vamos criar um arquivo assim:

```
echo -e "Debian\t\tEstável\t\tRápido\t\t10\nSlackware\tPsicopata\tAteu\t\t8\nUbuntu\t\tFácil\t\tSimple\t\t6" > distros.txt
```

Mostrar só a 1º coluna: **awk** '{print \$1}' distros.txt # 2,3, e 4 ...(...)

Mostrar só a 1º e a 3º colunas: **awk** '{print \$1 \$3}' distros.txt # NÃO haverá espaços entre as colunas

Mostrar só a 1º e a 3º colunas com espaços: **awk** '{print \$1, \$3}' distros.txt # HAVERÁ espaços entre as colunas

Adicionar informação entre as colunas: **awk** '{print \$1,"é",\$2}' distros.txt

Imprimindo texto com quebra de linha \n: **awk** 'BEGIN {print "Vai ser tudo \n imprimido \n agora\n"}'


Ainda dá pra usar CONDIÇÕES: **awk** '{ if(\$4 > 2000) print \$1 }' arquivo.txt

REDIRECIONAR SAÍDA: **awk** 'BEGIN {print 1+1 > "resultado.txt" }'

man awk

SED

sed é o mesmo que **Stream EDitor** ou editor de fluxo. Muito utilizado nos sistemas tipo **Unix**. Ao contrário dos editores convencionais, o **sed** atua em linha de comandos ou em **shell script**. Aceita expressões regulares, o que lhe confere maior poder, convertendo-se em uma excelente ferramenta para administradores de sistemas.



Sua sintaxe é: **sed** [opções] {script} [arquivo]

Alguns Exemplos de Comandos SED

Vamos usar esse texto de exemplo o `arquivo.txt`

O pinguim vive no frio ,mas no meu computador ele se chama tux e seu chão é resfriado pelo cooler e pasta térmica. O tux é o pinguim!

- * Troca todas ocorrências da palavra `tux` pela palavra `pinguim`: `sed 's/tux/pinguim/' arquivo.txt`
- * Troca ocorrências da palavra `pinguim` pela palavra `tux`: `sed 's/pinguim/tux/' arquivo.txt`
- * Imprime só as linhas com a palavra `cooler`: `sed -n '/cooler/p' arquivo.txt`
- * Deleta só as linhas com a palavra `resfriado`: `sed '/resfriado/d' arquivo.txt`
- * Retira todas `linhas em branco`: `sed '/^$/d' arquivo.txt`

Há uma postagem no blog *terminalroot.com.br* com 30 exemplos do comando sed:

30 exemplos do comando sed (com regex)

<http://terminalroot.com.br/2015/07/30-exemplos-do-comando-sed-com-regex.html>

Manual do sed : `man sed`

Glob NÃO é Regex!

Glob	Regex
.md	.\.md
[aeiou]*	[aeiou].*
filme.{flv,mp4}	filme\\. {flv mp4}
ferias-?? .png	ferias-\\. .png

O **Bash** não consegue reconhecer **expressões regulares**. Dentro de scripts, são comandos e utilitários - como **sed** e **awk** - que interpretam **REs**. O **Bash** executa a expansão do nome do arquivo - um processo conhecido como **glob** - mas isso não usa o conjunto padrão de **Expressões Regulares**.

Em vez disso, **globbing** reconhece e expande **wildcards** (em português significa **cUringa**, cuidado ao pronunciar/escrever , porque é com **U** e não **cØringa** com **O** que é outra coisa). São caracteres que podem ser usados em conjunto com comandos para substituir outros caracteres ou conjunto deles. Eles só pode ser usados com comandos que manipulam arquivos ou diretórios.

*Links úteis pra testar **REGEX** online*
<http://regexpal.com> e <http://regex101.com>